

DELTA

연합학습 환경에서 장기 시계열 예측을 위한
선택적 경량 TTA

이정운 · 임정환 · 민보경 · 권혁윤
서울과학기술대학교 BIGBASE Lab.

KCC 2026

장기 시계열 예측은 에너지 · 제조 · 기상 등 현실 세계 시스템의 핵심 과제.
그러나 시계열의 **비정상성**으로 학습 환경과 다른 배포 환경에서 성능 저하 발생.

1. 장기 시계열 예측의 중요성

에너지 수요 · 제조 공정 · 기상 변화 등 다양한 시스템의 핵심 역할

2. 비정상성 (Non-stationarity)

평균 · 분산 · 자기상관 등 통계적 특성이 시간에 따라 변하는 성질

3. 분포 이동 (Distribution shift)

학습 시점과 배포 시점의 통계 분포 차이로 모델 성능 저하

→ DLinear는 강한 backbone이지만, 배포 후 분포 이동에는 여전히 취약

1. Test-Time Adaptation (TTA)

배포 후 비라벨 데이터만으로 모델을 조정해 분포 이동에 대응하는 기법

2. 시계열 TTA의 위험

모델 붕괴·누적 오차로 성능 열화 위험 — 안정성 확보가 핵심 과제

3. 연합학습(FL) 환경의 요구

분산된 다수의 클라이언트가 글로벌 모델의 재학습 없이 개별적으로 국소 분포 변화에 대응

→ 안정적이면서 적응 비용이 낮은 선택적 경량 TTA가 필요

DELTA는 연합학습과 TTA를 결합한 Fed-TTA의 선행 단계

DELTA: backbone 동결, 저차원 adapter만 갱신, 분포 이동이 감지된 창에서만 선택적 적응

1. 사전학습

DLinear backbone 학습 후

각 클라이언트에 배포, 이후 backbone 동결

2. 온라인 추론

동결 backbone의 기본 예측에

time-affine adapter가 보정 출력 산출

3. 선택적 적응

Drift gate → Rollback guard → Update ϕ

→ Reset 규칙으로 필요한 윈도우만 갱신




그림 1. DELTA 전체 프레임워크



핵심 아이디어

- **Backbone 동결**
학습된 예측 모델 고정 → 안정성·효율 확보
- **저차원 Time-Affine Adapter ϕ 부착**
예측 출력 위에 scale · shift 보정만 적용
- **테스트 시 ϕ 만 갱신**
backbone 전체가 아닌 adapter만 학습
— 파라미터 0.6% 미만

Adapter 변환

$$\hat{y}_{\text{adapt}} = a \odot \hat{y} + b$$

a, b = adapter ϕ 의 scale · shift

목적함수

$$L(\phi) = L_{\text{rec}} + \lambda_{tc} L_{tc} + \lambda_{id} L_{id}$$

L_{rec} 최근 관측 구간의 복원 오차


L_{tc} 인접 윈도우 사이의 시간적 일관성 오차

L_{id} adapter를 항등변환 근처로 유지하는 정규화

방법 ② 선택적 적응 규칙



한국정보과학회 KIISE



→ 분포 이동이 감지된 창에서만 adapter 갱신, 나머지 창은 현재 adapter 유지

▪ 평가 지표

MSE · MAE · SMAPE
클라이언트 평균 기준

▪ 학습 설정

batch 256 · Centralized 15 epochs
FedAvg local 3 / global 15 rounds
hindcast k = 6 (H=96)

▪ 비교군

Backbone(FedAvg)
DELTA-(항상 적응)
DELTA(선택적 적응)

표 1. 데이터셋 및 backbone 설정

데이터셋	간격	입력길이	예측길이	커널크기	변량 수
Murata	15 min	192	96	49	30
Solar	10 min	288	96	73	137
Electricity	1 hour	336	96	25	321

입력 길이는 물리적 컨텍스트(48시간/14일),
커널 크기는 약 12시간(또는 1일) 트렌드 구간
기준으로 설계

결과 ① 기초 비교 — 대표 비교군 성능



가중치를 직접 갱신하는 접근법(Direct-weight TTA · Loop-based)은 backbone 대비 성능 미달

표 2. 대표 비교군의 예측 성능 비교

데이터셋	방식	MSE	MAE	SMAPE
Murata	Centralized	0.3064	0.3151	131.02
	Backbone (FedAvg)	0.3032	0.3075	130.73
	Direct-weight TTA	0.3188	0.3315	130.84
	Loop-based baseline	0.4068	0.3872	133.70
	DELTA-	0.3032	0.3075	130.72
Solar	Centralized	0.2232	0.2561	146.01
	Backbone (FedAvg)	0.2242	0.2567	146.00
	Direct-weight TTA	0.2268	0.2597	146.12
	Loop-based baseline	0.3268	0.3424	148.74
	DELTA-	0.2242	0.2566	146.02
Electricity	Centralized	0.1464	0.2434	12.57
	Backbone (FedAvg)	0.1533	0.2467	12.56
	Direct-weight TTA	0.2536	0.3116	15.33
	Loop-based baseline	0.1691	0.2731	14.11
	DELTA-	0.1530	0.2464	12.55

DELTA는 세 데이터셋 모두에서 backbone과 **동등한 정확도** 유지 — 상대 MSE 열화 $\leq 0.5\%$

표 4. Backbone, DELTA-, DELTA 정확도 비교

데이터셋	방식	MSE	MAE	SMAPE
Murata	Backbone	0.3032	0.3075	130.73
	DELTA-	0.3032	0.3075	130.72
	DELTA	0.3032	0.3076	130.72
Solar	Backbone	0.2242	0.2567	146.00
	DELTA-	0.2242	0.2566	146.02
	DELTA	0.2242	0.2567	146.02
Electricity	Backbone	0.1533	0.2467	12.56
	DELTA-	0.1532	0.2465	12.56
	DELTA	0.1532	0.2465	12.56

결과 ③ 적응 효율 — 핵심 성과



한국정보과학회 KIISE



47.3%

Murata 적응 윈도우 감소

39.8%

Solar 적응 윈도우 감소

< 0.6%

학습 파라미터 비율

$\leq 0.02\%$

MSE 열화 (No-harm)

공통 drift gate threshold = 1.0 선택 — no-harm 만족하면서 평균 적응 비율 최소화

파라미터 0.6% 미만 → 자원이 제한된 현장 클라이언트도 **backbone** 전체 갱신 없이 적응 가능

결론

- backbone 동결 + 선택적 drift gate를 결합한 경량 TTA 구조 DELTA 제안
- 적응 윈도우를 절반 가까이 감소하면서 MSE 열화 0.02% 이내 유지 (no-harm)
- 제한된 연합학습 환경에서의 실효성 입증

향후 연구

- 다양한 배포 조건에서의 검증 확장
- 서버-클라이언트 조율을 포함한 확장된 Fed-TTA 구조로 발전

감사합니다

Q & A

이정윤 · 서울과학기술대학교 BIGBASE Lab · jy020605@seoultech.ac.kr