

GATE: 장기 시계열 예측에서 정확도를 유지하는 선택적 경량 테스트 시 적응

GATE: Selective Lightweight Test-Time Adaptation for Accurate Long-term Time-series Forecasting

요약

본 논문은 DLinear 기반 장기 시계열 예측에서 분포 이동에 안정적으로 대응하는 선택적 경량 테스트 시 적응(TTA) 구조인 GATE를 제안한다. GATE는 backbone을 동결한 채 저차원 time-affine adapter만 갱신하고, rollback guard, drift gate, acceptance gate, reset rule을 결합해 필요한 창에서만 선택적으로 적응한다. Murata, Electricity, Solar 데이터셋에서 공통 drift gate(threshold 1.0)를 적용한 결과, Murata와 Solar에서 적응 윈도우 비율을 각각 47.3%, 39.8% 줄이면서 MSE 열화를 0.02% 이내로 유지하였고, Electricity에서는 MSE가 오히려 0.097% 개선되었다(bootstrap 95% CI 기준 통계적으로 유의). 본 연구는 연합학습(FL) 배포 환경을 목표로 한 클라이언트 측 선택적 TTA 기반을 확립하며, 향후 서버-클라이언트 간 gate 및 adapter 조율을 포함하는 Fed-TTA로의 확장을 지향한다.

1. 서론

장기 시계열 예측에서는 DLinear [1]와 같은 효율적인 backbone이 강한 기준선으로 자리잡았지만, 훈련 시점과 배포 시점 사이의 분포 이동(distribution shift)은 실제 환경에서 빈번하게 발생한다 [2]. 이에 대응하기 위해 테스트 단계의 비라벨 데이터만으로 모델을 조정하는 test-time adaptation(TTA)이 활발히 연구되었으나 [3, 4], 시계열 환경에서의 TTA는 모델 붕괴나 누적 오차로 인한 성능 열화 위험이 크고, 적응 비용을 줄이면서도 안정성을 보장하는 것이 핵심 과제로 남아 있다 [5]. 이 문제는 스마트 팩토리 센서나 태양광 발전 패널처럼 기기마다 환경이 다른 연합학습(Federated Learning, FL) 배포 환경을 목표로 할 때 더욱 중요해진다 [6]. FL 환경에서는 각 클라이언트가 중앙 서버 재학습 없이 배포 이후의 국소 분포 변화에 스스로 대응해야 한다. 이처럼 FL과 TTA를 결합해 각 클라이언트가 로컬 적응을 수행하는 체계를 Fed-TTA로 정의하며, 본 연구는 그 선행 단계로서 DLinear backbone을 동결한 채 time-affine adapter만 갱신하고, drift gate, rollback guard, acceptance gate를 결합해 필요한 창에서만 적응하는 GATE를 제안한다 [1, 7].

2. 관련 연구

2.1 시계열 예측과 비정상성

장기 시계열 예측에서는 복잡한 Transformer 계열 대신 선형 구조로도 높은 성능과 효율을 보인 DLinear [1]가 강한 기준선으로 자리잡았다. 그러나 실제 시계열은 시간에 따라 통계적 특성이 변하는 비정상성을 띠며, 이러한 분포 이동은 학습된 모델의 성능 저하로 이어진다. RevIN [8]과 같은 정규화 기법은 윈도우 단위 통계 변화를 완화하는데 효과적이지만, 배포 이후 새 환경에서 지속적으로 발생하는 drift 자체를 해결하지는 못한다. GATE는 이 지점에서 backbone을 유지한 채 배포 시점의 국소 변화만 경량 보정하는 방식을 취한다.

2.2 테스트 시 적응과 안정성

연합학습은 프라이버시 보존형 분산 학습의 대표 틀로 발전해 왔지만 클라이언트 간 통계적 이질성은 여전히 핵심 난제이며, 이는 단일 글로벌 모델의 일관된 일반화를 어렵게 한다. [9] 따라서 배포 이후 발생하는 클라이언트별 분포 이동에 대응하기 위해 비라벨 데이터로 모델을 조정하는 테스트 시 적응(TTA)과 같은 로컬 보정 기제가 요구된다. 다만 동적 환경에서의 TTA는 성능 열화 위험이 커 안정성 보장이 필수적이며, 최근에는 메모리와 적응 비용을 줄이기 위해 일부 파라미터만 조정하는 경량 적응 방식이 제안되고 있다. 향후 서버-클라이언트 간 조율을 포함하는 완전한 Fed-TTA를 구성하려면 클라이언트 측에서 안정적으로 동작하는 선택적 TTA 기반이 선행되어야 한다. 본 연구는 이 선행 과제에 집중하며, backbone을 동결하고 선택 규칙을 통과한 창에서만 adapter를 갱신하는 보수적 TTA 구조를 취한다.

3. 제안 방법

3.1 프레임워크 개요

그림 1은 GATE의 전체 파이프라인을 세 단계로 보여준다.

- 사전학습 단계에서는 historical train windows로 DLinear backbone Θ^* 를 학습하여 global scaling + RevIN [8] 처리 후 각 클라이언트에 배포하며, 이후 테스트 시점에 backbone은 동결된다.
- 온라인 추론 단계에서는 동결 backbone Θ^* 가 기본 예측 $\hat{Y}_{bb}$ 를 생성하면 time-affine adapter $\phi = (\gamma, \delta)$ 가 $\hat{Y}_{Y_final} = \gamma \odot \hat{Y}_{bb} + \delta$ 를 출력한다.
- 선택적 적응 단계에서는 Drift gate $\rightarrow$ Rollback guard $\rightarrow$ Update ϕ only $\rightarrow$ Acceptance gate의 네 단계 선택 규칙이 순차적으로 작동하며, 분포 이동이 감지된 창에서만 adapter ϕ 를 갱신하고 나머지 창은 현재 adapter를 유지한다. 본 연구는 서버-클라이언트 간 조율을 포함하는 Fed-TTA의


메모 포함[임1]: 시계열 예측의 필요성 및 Nontationarity에 대한 설명 1문단 추가.

메모 포함[임2]: 연합학습 or FL 용어 통일

메모 포함[임3]: Notaion 점검. YhatY_bb??

선행 단계로서 [3, 4, 5], 클라이언트 측에서 필요한 창에만 선택적으로 적응하는 안정적 로컬 TTA 기반 확립에 초점을 둔다.

그림1. GATE 전체 프레임워크



3.2 동결 Backbone과 Time-Affine Adapter

본 연구에서는 안정성과 효율을 위해 backbone을 동결하고 예측 출력 위에 저차원 time-affine adapter를 부착한다 [7].

$$\hat{Y}_{final} = Y \odot \hat{Y}_{backbone} + \delta$$

여기서 $\hat{Y}_{backbone}, \hat{Y}_{final} \in \mathbb{R}^{B \times H \times C}$ 이고, $Y, \delta \in \mathbb{R}^{1 \times H \times C}$ 이다. 따라서 테스트 시점에는 backbone 전체가 아니라 $\phi = (Y, \delta)$ 만 갱신한다. adapter의 목적함수는 다음과 같다.

$$\mathcal{L}_{affine} = \alpha_{eff} \mathcal{L}_{cons} + \beta_{eff} \mathcal{L}_{hind} + \lambda_{anchor} \mathcal{L}_{anchor}$$

여기서 $\mathcal{L}_{hind}$ 는 최근 관측 구간에 대한 복원 오차, $\mathcal{L}_{cons}$ 는 인접 윈도우 사이의 시간적 일관성 오차, $\mathcal{L}_{anchor}$ 는 adapter가 항등변환 근처에 머물도록 하는 정규화 항이다.

$$\mathcal{L}_{hind} = \frac{1}{BkC} \|\hat{Y}_{1:k}^{curr} - X_{1:k}^{recent}\|_2^2$$
$$\mathcal{L}_{cons} = \frac{1}{B(H-1)C} \|\hat{Y}_{1:H-1}^{curr} - sg(\hat{Y}_{2:H}^{prev})\|_2^2$$
$$\mathcal{L}_{anchor} = \frac{\|Y - 1\|_2^2 + \|\delta\|_2^2}{C}$$

여기서 $1:k$ 와 $2:H$ 는 horizon index를, $sg(\cdot)$ 는 stop-gradient를 뜻한다. 또한 hindcast 오차에 따라 $boost$ 를 계산하고 α 와 β 를 재조정한다.

$$boost = \min(1 + \rho \cdot sg(\mathcal{L}_{hind}), boost_{max})$$
$$\alpha_{eff} = \frac{\alpha}{boost}, \quad \beta_{eff} = \beta \cdot boost$$

3.3 선택적 적응 규칙

GATE는 모든 테스트 창에서 adapter를 갱신하지 않고, 사전 정의한 규칙을 만족할 때만 적응을 수행한다. 먼저 drift gate는 사전 drift score가 임계값 이상인 창에서만 적응을 시도한다. rollback guard는 현재 창의 사전 hindcast 오차가 과거 rolling mean에 비해 과도하게 크면 업데이트를 생략한다. 적응 후에는 acceptance gate를 적용해

$\mathcal{L}_{hind}^{post} \leq (1 - m)\mathcal{L}_{hind}^{pre}$ 를 만족하는 경우에만 갱신을 수용한다. 마지막으로 업데이트 이후 hindcast 손실이 reset threshold를 넘으면adapter를 항등변환으로 초기화한다.

표1. 데이터셋 및 backbone 설정

데이터셋	간격	입력길이	예측길이	커널크기
Murata	15 min	192	96	49
Solar	10 min	288	96	73
Electricity	1 hour	336	96	25

표2. 대표 비교군 결과

데이터셋	방식	MSE	MAE	sMAPE
Murata	Centralized	0.3064	0.3151	131.02
Murata	FedAvg bb	0.3032	0.3075	<u>130.73</u>
Murata	Direct TTA	0.3188	0.3315	130.84
Murata	Loop baseline	0.4068	0.3872	133.70
Murata	Time-affine	0.3032	0.3075	130.72
Electricity	Centralized	0.1464	0.2434	12.57
Electricity	FedAvg bb	0.1533	0.2467	12.56
Electricity	Direct TTA	0.2536	0.3116	15.33
Electricity	Loop baseline	0.1691	0.2731	14.11
Electricity	Time-affine	<u>0.1530</u>	<u>0.2464</u>	12.55
Solar	Centralized	0.2232	0.2561	<u>146.01</u>
Solar	FedAvg bb	<u>0.2242</u>	0.2567	146.00
Solar	Direct TTA	0.2268	0.2597	146.12
Solar	Loop baseline	0.3268	0.3424	148.74
Solar	Time-affine	<u>0.2242</u>	<u>0.2566</u>	146.02

4. 실험

4.1 실험 설정 및 평가 프로토콜

평가 지표는 클라이언트 평균 기준의 MSE, MAE(역정규화 직후 계산), SMAPE(원단위 역정규화 후 계산)를 사용하였다. 공통 학습 설정은 batch size 256, centralized 15 epochs, FedAvg local 3 epochs 및 global 150 rounds로 고정하였다.

성능 평가는 Centralized 방식과 내부 기준선(direct-weight TTA, loop-based baseline)을 포함하여 보고하되, 본문의 주된 비교는 'FedAvg backbone', 항상 적응을 수행하는 'Control (drift gate 비활성화)', 그리고 '공통 drift gate'를 적용한 'GATE' 세 가지를 중심으로 수행한다. 이때 GATE의 공통 임계값(threshold)은 후보군 [0.3, 0.5, 1.0] 중에서 backbone 대비 상대 MSE 열화가 0.5% 이하이면서 평균 적응 비율을 가장 낮추는 값으로 선택하였다.

4.2 기초 비교 결과

표 2는 대표 비교군 결과를 요약한다. 내부 비교군인 direct-weight TTA와 loop-based baseline은 세 데이터셋에서 backbone을 일관되게 넘지 못하였다. 반면 동결 backbone 기반 time-affine은 치명적 성능 저하를 줄이면서 backbone과 준동등 수준의 정확도를 유지하였다. 따라서 이후 평가는 동결 backbone 기반의 선택적 적응에 초점을 두었다.

표3. 공통 drift gate threshold 탐색 결과

메모 포함[임4]: 그림 내 폰트 크기 확대.

메모 포함[임6]: 데이터셋 별 입력 길이, 커널 크기가 다른 이유? 변량 개수는?

메모 포함[임7]: 데이터셋 제시 순서와 동일하게 변경.

메모 포함[임8R7]: 4.1 이후에 오도록 조정.

메모 포함[임9R7]: 표2 표4를 왜 따로 제시하는지?

메모 포함[임5]: DLinear 이외에 다른 모델에도 적용 가능해보이는데?

임계값	Murata ΔMSE(%)	Elec. ΔMSE(%)	Solar ΔMSE(%)	평균적응비율
0.3	<u>0.021</u>	-0.097	<u>0.003</u>	<u>0.846</u>
0.5	<u>0.021</u>	-0.097	<u>0.003</u>	<u>0.846</u>
1.0	0.015	<u>-0.096</u>	0.000	0.605

표4. Backbone, Control, 공통 drift gate 정확도 비교				
데이터셋	방식	MSE	MAE	sMAPE
Murata	Backbone	0.3032	0.3075	<u>130.73</u>
Murata	Control	0.3032	0.3075	130.72
Murata	Shared gate	0.3032	<u>0.3076</u>	130.72
Electricity	Backbone	<u>0.1533</u>	<u>0.2467</u>	12.56
Electricity	Control	0.1532	0.2465	12.56
Electricity	Shared gate	0.1532	0.2465	12.56
Solar	Backbone	0.2242	<u>0.2567</u>	146.00
Solar	Control	0.2242	0.2566	<u>146.02</u>
Solar	Shared gate	0.2242	<u>0.2567</u>	<u>146.02</u>

표5. 공통 gate 적용 시 적응 효율 비교					
데이터셋	기준선적응	게이트 적응	드리프트 생략	볼백 생략	파라미터 비율
Murata	0.778	0.410	0.555	0.034	0.518%
Electricity	0.913	0.894	0.021	0.085	0.297%
Solar	0.847	0.510	0.414	0.076	0.346%

4.3 공통 Gate 결과

표 3은 time-affine Control을 기준으로 drift gate threshold를 탐색한 결과이다. ΔMSE(%)는 $100 \cdot (\text{gated} - \text{backbone}) / \text{backbone}$ 으로 정의하며, 음수는 backbone 대비 개선을 의미한다.

세 후보 모두 no-harm 기준을 만족했으며, threshold 1.0이 평균 적응 비율을 가장 낮추어 공통 drift gate로 선택되었다.

표 4은 backbone, Control, 공통 drift gate의 최종 정확도 비교를 보여준다. 공통 drift gate는 세 데이터셋 모두에서 backbone과 준동등 수준의 정확도를 유지했으며, 상대 MSE 열화도 사전 정의한 $\leq 0.5\%$ 범위 안에 머물렀다. 클라이언트 단위 bootstrap 신뢰구간은 부록 표 6에 제시하였다.

4.4 적응 효율

표 5는 공통 drift gate 적용 시 적응과 생략 비율의 변화를 정리한 것이다. Murata와 Solar에서는 적응 비율 감소가 크게 나타났고, Electricity에서는 감소폭이 작았다. 학습 가능 파라미터 비율은 세 데이터셋 모두에서 0.6% 미만이었다.

5. 결론 및 향후 연구

본 연구는 장기 시계열 예측 시 안정성과 연산 효율을 높이기 위해, backbone을 동결하고 선택적 drift gate를 결합한 경량 TTA 구조인 GATE를 제안하였다. 실험 결과, 적응 윈도우 비율을 절반 가까이 줄이면서도 성능 열화를 최소화(MSE 0.02% 이내)하여, 제한된 엣지 디바이스 및 연합학습(FL) 환경에서 클라이언트 단독으로 달성할 수 있는 실질적 효율성을 입증하였다.

다만, 단일 시드 실험으로 인한 통계적 분산 평가의 부재와

FLOPs 등 실측 시간 기반의 효율성 검증이 부족하다는 한계가 있다. 향후 다중 시드 평가 및 최신 시계열 backbone과의 비교를 통해 본 TTA 기반을 강화하고, 나아가 파라미터 병합 등 서버-클라이언트 간 조율 레이어를 도입하여 완전한 Fed-TTA로 확장할 계획이다.

참고문헌

[1] A. Zeng, M. Chen, L. Zhang, and Q. Xu, “Are transformers effective for time series forecasting?”, in Proceedings of the AAAI Conference on Artificial Intelligence, vol. 37, pp. 11121–11128, 2023.

[2] Y. Liu, H. Wu, J. Wang, and M. Long, “Non-stationary transformers: Exploring the stationarity in time series forecasting,” in Advances in Neural Information Processing Systems, vol. 35, pp. 9881–9893, 2022.

[3] Y. Sun, X. Wang, Z. Liu, J. Miller, A. A. Efros, and M. Hardt, “Test-time training with self-supervision for generalization under distribution shifts,” in Proceedings of the 37th International Conference on Machine Learning, vol. 119 of Proceedings of Machine Learning Research, pp. 9229–9248, 2020.

[4] D. Wang, E. Shelhamer, S. Liu, B. Olshausen, and T. Darrell, “TENT: Fully test-time adaptation by entropy minimization,” in Proceedings of the International Conference on Learning Representations, 2021.

[5] S. Niu, J. Wu, Y. Zhang, Z. Wen, Y. Chen, P. Zhao, and M. Tan, “Towards stable test-time adaptation in dynamic wild world,” in Proceedings of the International Conference on Learning Representations, 2023.

[6] B. McMahan, E. Moore, D. Ramage, S. Hampson, and B. A. y Arcas, “Communication-efficient learning of deep networks from decentralized data,” in Proceedings of the International Conference on Artificial Intelligence and Statistics, pp. 1273–1282, 2017.

[7] J. Song, J. Lee, I. S. Kweon, and S. Choi, “EcoTTA: Memory-efficient continual test-time adaptation via self-distilled regularization,” in Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pp. 28628–28638, 2024.

[8] T. Kim, J. Kim, Y. Tae, C. Park, J.-H. Choi, and J. Choo, “Reversible instance normalization for accurate time-series forecasting against distribution shift,” in Proceedings of the International Conference on Learning Representations, 2022.

[9] T. Li, A. K. Sahu, M. Zaheer, M. Sanjabi, A. Talwalkar, and V. Smith, “Federated optimization in heterogeneous networks,” in Proceedings of Machine Learning and Systems, vol. 2, pp. 429–450, 2020.